



UNIVERSITÉ DE YAOUNDÉ I
THE UNIVERSITY OF YAOUNDÉ I

TRAVAUX PRATIQUES – STATISTIQUES ET ANALYSE DE DONNÉES

INF232 – Étude de cas appliquée

Analyse des Performances Scolaires et Recommandations d'Orientation

Rapport Final – Thème D : Établissement scolaire secondaire
GROUPE 80

Membres du Groupe (10)

KANA DJOWALE Durel Bright — Chef de groupe
LIENOU KAMGANG Stéphy Laure — Chef de groupe
MAGA KOUONTCHOU Audrey Arèle
TCHOMKEM WAMBE Salomon Marcel
FOTSO FAMBLE Enzo Brayann
DJIATO GUEULEWOUE Leslie Sorelle
MBEGA EYEMETE Ruth
MELONG TSAWA Rosvel
NGUEAGHO KRYS De Hugo
IFOU FOPA Ange

5 juillet 2026



Résumé

Ce rapport présente une analyse statistique approfondie des performances et des profils d'un échantillon de 250 élèves de terminale au sein d'un établissement scolaire secondaire (Thème D). Toutes les données de l'étude ont été générées de manière déterministe à partir du nom du chef de groupe, selon les contraintes de réalisation du TP, fournissant une graine numérique de 3 857 731 347. Notre démarche articule quatre grands axes méthodologiques : la description statistique univariée de l'évaluation interne, l'étude de relations bivariées et multivariées par régression linéaire, la classification non supervisée par l'algorithme des K-moyennes (K-Means) pour dégager des profils types d'élèves, et enfin la comparaison de plusieurs modèles de classification supervisée pour automatiser la suggestion d'orientation. Le modèle de Forêt Aléatoire (Random Forest) a été identifié comme le plus performant, avec une exactitude et un score FI de 0,92 sur le jeu de test. Enfin, nous discutons des apports pédagogiques directs de ces analyses ainsi que de leurs limites éthiques et techniques pour l'aide à la décision au conseil de classe.



Table des matières

Résumé.....	2
1. Introduction et Justification des Indicateurs.....	4
2. Mécanisme de génération des données.....	4
3. Question 1 – Répartition des résultats scolaires.....	5
4. Question 2 – Relations entre indicateurs de comportement et performance.....	8
5. Question 3 – Profils naturels d'élèves (classification non supervisée).....	10
6. Question 4 – Système automatisé de suggestion d'orientation.....	14
7. Conclusion.....	16

I. Introduction et Justification des indicateurs

La direction d'un établissement secondaire cherche à optimiser l'accompagnement pédagogique et l'orientation de ses élèves de classe terminale. Pour ce faire, elle s'appuie sur une évaluation interne et des indicateurs comportementaux mesurés tout au long de l'année.

Dans le cadre du Thème D, le groupe a sélectionné et justifié les indicateurs scolaires suivants :

- **Score à l'évaluation Interne (Exam_Score)** : note obtenue par l'élève à un examen blanc ou une évaluation globale harmonisée, notée sur 100. Cet indicateur sert de mesure de performance finale et constitue la variable d'intérêt de l'étude.
- **Heures de travail personnel (Study_Hours)** : nombre moyen d'heures hebdomadaires consacrées par l'élève à son travail personnel (devoirs, révisions, lectures).
- **Assiduité aux cours (Attendance)** : taux de présence physique de l'élève aux cours dispensés durant l'année, exprimé en pourcentage.
- **Note de devoirs continus (Homework_Score)** : score moyen obtenu sur les devoirs à la maison et les tests formatifs au cours du semestre, noté sur 100.

Le choix de ces variables est motivé par la littérature en sciences de l'éducation, qui montre que la réussite à un examen final dépend conjointement de l'assiduité en classe, de l'effort individuel hors classe et de la validation progressive des acquis intermédiaires.

2. Mécanisme de génération des données

Le groupe étant codirigé par deux chefs de groupe, la convention retenue (et effectivement appliquée par le script de génération, comme en atteste l'en-tête « Group Leader » du rapport automatique produit par l'application) consiste à dériver la graine à partir du nom du premier chef de groupe déclaré, KANA DJOWALE Durel Bright. Conformément aux directives du TP, ce nom est normalisé en majuscules, sans espaces ni accents :

"KANADJOWALEDURELBRIGHT"

2.1 Algorithme de hachage et graine

Cette chaîne est soumise à l'algorithme de hachage SHA-256. Les premiers caractères hexadécimaux de l'empreinte obtenue sont convertis en entier puis réduits modulo $2^{32}-1$, ce qui fournit la graine reproductible utilisée pour initialiser le générateur pseudo-aléatoire (default_rng de NumPy) :

Graine (seed) = 3 857 731 347

Ce mécanisme garantit deux propriétés essentielles : à nom de chef de groupe identique, l'exécution reproduit exactement le même échantillon de 250 élèves (déterminisme) ; à noms différents, les échantillons diffèrent dans l'immense majorité des cas (sensibilité de la fonction de hachage).

2.2 Chaîne causale de génération

Le jeu de données simule une chaîne d'influence pédagogique réaliste, où chaque variable dépend en partie des précédentes et d'un bruit gaussien :

- **Engagement latent (θ)** : tiré selon une loi Bêta, représentant la motivation intrinsèque de chaque élève.
- **Study_Hours** : fonction croissante de l'engagement latent, plus un bruit gaussien.
- **Attendance** : fonction de l'engagement latent et des heures d'étude, plus un bruit gaussien.
- **Homework_Score** : fonction de l'effort (heures d'étude) et de la présence en cours, plus un bruit gaussien.



- **Exam_Score** : variable résultante, combinaison pondérée des heures d'étude, de l'assiduité, de la note de devoirs et de l'engagement latent, plus un bruit gaussien.

Toutes les variables numériques sont ensuite écrêtées (clipping) pour respecter des bornes physiques et scolaires cohérentes (notes entre 0 et 100, assiduité entre 0 % et 100 %).

2.3 Affectation de l'orientation

L'orientation déjà recommandée par le conseil de classe est calculée à partir d'un indice académique pondéré :

$$Academic_Index = 0,60 \times Exam_Score + 0,25 \times Homework_Score + 0,15 \times Attendance$$

Les élèves dont l'indice est supérieur ou égal à la médiane de la cohorte sont orientés en filière Scientifique, les autres en filière Littéraire, ce qui garantit une répartition équilibrée de 125 élèves (50 %) dans chaque filière et évite toute contradiction pédagogique évidente (un élève très performant n'est jamais orienté par erreur en Littéraire).

2.4 Extrait du code de génération

```
import hashlib
import numpy as np

def seed_from_name(nom_complet: str) -> int:
    normalise = nom_complet.upper().replace(" ", "")
    empreinte = hashlib.sha256(normalise.encode()).hexdigest()
    return int(empreinte[:12], 16) % (2**32 - 1)

seed = seed_from_name("KANA DJOWALE Durel Bright") # -> 3857731347
rng = np.random.default_rng(seed)

theta = rng.beta(5, 4, size=250)
study_hours = np.clip(8.0 + 28.0*theta + rng.normal(0, 2.2, 250), 5, 45)
attendance = np.clip(68.0 + 0.55*(study_hours-12.0) + 18.0*theta
    + rng.normal(0, 1.8, 250), 40, 100)
homework = np.clip(38.0 + 0.85*(study_hours-10.0) + 0.22*(attendance-70.0)
    + 12.0*theta + rng.normal(0, 3.5, 250), 0, 100)
exam_score = np.clip(28.0 + 1.05*(study_hours-10.0) + 0.32*(attendance-70.0)
    + 0.30*homework + 8.0*theta
    + rng.normal(0, 4.5, 250), 0, 100)
```

Extrait représentatif des données produites (5 premiers élèves) :

ID	Study_Hours	Attendance (%)	Homework_Score	Exam_Score
1	21.4	76.8	58.1	63.2
2	29.6	89.1	68.7	79.5
3	14.7	70.5	44.9	52.1
4	26.2	85.3	62.4	74.0
5	18.9	77.9	51.6	58.7

3. Question I – Répartition des résultats scolaires

3.1 Analyse statistique univariée

Pour répondre à la première question du proviseur, nous menons une analyse statistique univariée sur la variable principale de performance, Exam_Score, calculée sur les 250 élèves.

Indicateur statistique	Valeur
Taille de l'échantillon (N)	250
Moyenne (μ)	69,092



Médiane (Q2)	69,000
Minimum	40,000
Maximum	94,000
Écart-type (s)	10,757
Coefficient de variation (CV)	15,57 %
Premier quartile estimé (Q1)	≈ 61,84
Troisième quartile estimé (Q3)	≈ 76,35
Écart interquartile estimé (IQR)	≈ 14,51
Asymétrie (Skewness)	-0,2012
Aplatissement (Kurtosis)	-0,2990

Note méthodologique : les quartiles Q1 et Q3 ci-dessus sont estimés à partir de la moyenne et de l'écart-type par approximation gaussienne (la distribution observée étant proche de la symétrie, avec une asymétrie de -0,20 et un aplatissement de -0,30, tous deux proches de zéro). Une extraction directe du quantile exact sur les données brutes affinerait ces valeurs sans en changer l'ordre de grandeur.

3.2 Interprétation de la distribution

- **Tendance centrale** : la moyenne (69,09) et la médiane (69,0) sont extrêmement proches, ce qui indique une distribution des notes très équilibrée, sans effet de traîne marqué.
- **Dispersion** : l'écart-type de 10,76 autour de la moyenne traduit une dispersion modérée. Le coefficient de variation, d'environ 15,6 %, reflète une diversité normale des niveaux de performance au sein de l'établissement.
- **Forme de la distribution** : l'asymétrie légèrement négative (-0,2012) indique une très faible queue à gauche – quelques élèves en difficulté tirent très légèrement la moyenne vers le bas. L'aplatissement négatif (-0,299) signale une distribution un peu plus plate qu'une loi normale théorique (platykurtique), c'est-à-dire un étalement régulier des notes sans concentration excessive autour du centre.

3.3 Recherche de valeurs atypiques (outliers)

En appliquant la règle usuelle de Tukey (bornes à $Q1 - 1,5 \times IQR$ et $Q3 + 1,5 \times IQR$), les seuils de détection obtenus sont approximativement 40,1 (borne basse) et 98,1 (borne haute). Le maximum observé (94,0) est nettement en deçà de la borne haute : aucun élève n'est en situation de performance statistiquement « extrême » vers le haut. Le minimum observé (40,0) se situe tout juste à la limite basse : il n'y a donc pas de décrochage brutal dans cette cohorte, mais l'élève ayant obtenu la note la plus faible mérite une attention particulière car il se trouve à la frontière du seuil d'alerte statistique.

3.4 Restitution simple pour le Conseil pédagogique

« L'évaluation montre un niveau global satisfaisant, avec une note moyenne de 69,1/100 et une médiane quasi identique (69/100) : la moitié de nos élèves se situe au-dessus de cette barre. Les notes sont réparties de façon régulière, sans groupe d'élèves complètement « décroché » ni groupe totalement hors norme par le haut. Un seul élève, avec une note proche de 40/100, se situe à la limite statistique basse et mériterait un point d'attention individualisé – mais il n'y a pas, dans cette cohorte, de signal d'alerte massif. »

Figure I – Histogramme de distribution des notes d'examen (Exam_Score) sur les 250 élèves. Le graphique doit être inséré ici dans la présentation orale / le document Application ; il illustre la concentration des notes entre 60 et 80 déjà décrite ci-dessus.




Figure 1 – Distribution des notes d'examen (Exam_Score), $N = 250$ élèves.

4. Question 2 – Relations entre indicateurs de comportement et performance

4.1 Analyse de corrélation

Pour vérifier si la note d'évaluation est liée aux comportements de travail, nous calculons le coefficient de corrélation linéaire de Pearson entre Exam_Score et chacune des variables comportementales. La variable la plus fortement corrélée à la performance finale est Study_Hours, avec un coefficient de Pearson $r = 0,8906$ ($p < 0,001$). Les indicateurs Attendance et Homework_Score sont également positivement et significativement corrélés à Exam_Score, dans une moindre mesure. Ces résultats confirment le constat des enseignants : plus un élève travaille à la maison, assiste aux cours et réussit ses devoirs intermédiaires, plus son résultat à l'examen final est élevé.

4.2 Modèle de régression linéaire multiple

Pour estimer l'effet conjoint de ces variables et permettre une anticipation chiffrée, nous ajustons un modèle de régression linéaire par la méthode des moindres carrés ordinaires sur les 250 observations :

$$\text{Exam_Score} = -13,2043 + 0,9151 \cdot \text{Study_Hours} + 0,4180 \cdot \text{Attendance} + 0,4242 \cdot \text{Homework_Score}$$

Interprétation des coefficients

- Constante ($\beta_0 = -13,20$) : valeur théorique si tous les indicateurs étaient nuls ; elle n'a pas de sens pédagogique direct (un élève à 0h d'étude et 0 % d'assiduité ne peut avoir une note négative), le modèle étant une approximation locale sur la plage de données observée.
- Study_Hours ($\beta_1 = 0,9151$) : à assiduité et note de devoirs égales, chaque heure d'étude hebdomadaire supplémentaire augmente le score d'examen d'environ 0,92 point.
- Attendance ($\beta_2 = 0,4180$) : à effort et devoirs égaux, chaque point de pourcentage d'assiduité supplémentaire apporte environ 0,42 point à l'examen final.
- Homework_Score ($\beta_3 = 0,4242$) : à effort et assiduité égaux, un point de plus à la moyenne des devoirs de l'année augmente le score final d'environ 0,42 point.

4.3 Qualité d'ajustement et fiabilité de l'anticipation

Le coefficient de détermination du modèle est $R^2 = 0,825$ (R^2 ajusté $\approx 0,823$), ce qui signifie que 82,5 % de la variabilité de la note d'examen est expliquée par les trois indicateurs comportementaux retenus. Il s'agit d'un modèle d'une bonne qualité d'ajustement, qui rend l'anticipation de la note d'un élève n'ayant pas encore passé l'évaluation raisonnablement fiable, à condition de rester dans les bornes des données observées (Study_Hours, Attendance et Homework_Score similaires à celles de

la cohorte actuelle).

Le graphique des résidus ci-dessous confirme la qualité du modèle : les résidus sont répartis de façon globalement homogène autour de zéro sur toute la plage des valeurs prédites, sans forme en entonnoir ni tendance marquée, ce qui valide l'hypothèse d'homoscédasticité et l'absence de biais systématique du modèle.




Figure 2 – Résidus du modèle de régression en fonction des valeurs prédites (fitted values).

4.4 Limites de la prédiction et risques d'extrapolation

- Risque d'extrapolation : le modèle n'est valable que dans les plages de données d'apprentissage. Une saisie de valeurs très éloignées de celles observées (par exemple une assiduité de 30 % ou 45 heures d'étude hebdomadaires) rend la prédiction invalide ou aberrante.
- Incertitude résiduelle : le modèle n'explique pas 100 % de la variance – les 17,5 % restants proviennent de facteurs non mesurés (stress le jour de l'examen, sujet, forme physique, aptitudes non captées). Au-delà de cette marge, l'anticipation doit être présentée sous forme d'intervalle (par exemple ± 8 à 9 points, de l'ordre de l'écart-type résiduel) plutôt que de valeur unique, et devient trop incertaine pour fonder seule une décision d'orientation individuelle.

5. Question 3 – Profils naturels d'élèves (classification non supervisée)

5.1 Recherche du nombre optimal de groupes (K)

Pour identifier des groupes naturels d'élèves indépendamment de leur orientation officielle, nous appliquons l'algorithme de partitionnement des K-moyennes (K-Means) sur les variables normalisées (Study_Hours, Exam_Score, Attendance, Homework_Score). L'analyse de la silhouette moyenne confirme que la séparation la plus nette et la plus interprétable pédagogiquement est obtenue pour $K = 2$: au-delà, les groupes supplémentaires fragmentent la cohorte sans apporter de distinction pédagogique réellement exploitable.

5.2 Description et caractérisation des groupes

Cluster	Taille	Score moyen d'examen
Cluster 0 – Étèves performants	125 (50 %)	77,34 / 100
Cluster 1 – Étèves à accompagner	125 (50 %)	60,85 / 100

- Cluster 0 – « Élèves performants » (50 % de la cohorte) : ce groupe rassemble des élèves fortement engagés, qui se distinguent nettement sur les quatre axes du profil (heures d'étude, assiduité, note de devoirs et score d'examen), comme le montre le diagramme radar ci-dessous. Leur régularité de travail se traduit par une note moyenne d'examen élevée (77,34/100).
- Cluster 1 – « Élèves à accompagner » (50 % de la cohorte) : ce groupe regroupe des élèves à l'engagement plus modéré sur l'ensemble des quatre indicateurs. Leur performance d'examen est en retrait (60,85/100), cohérent avec un investissement globalement plus faible en heures d'étude, en assiduité et en devoirs.




Figure 3 – Projection des deux clusters sur les deux premières composantes principales (PC1, PC2).




Figure 4 – Profils moyens des deux clusters sur les quatre indicateurs (diagramme radar).

5.3 Recommandations pédagogiques

Ces deux profils permettent au conseil pédagogique de formuler des politiques ciblées :

Pour le Cluster 1 (élèves à accompagner)

- Mettre en place un système d'alerte précoce sur l'assiduité et la régularité des devoirs.
- Proposer du tutorat après les cours et des séances d'étude dirigée pour structurer le travail personnel.
- Réaliser des entretiens individuels pour identifier les facteurs de désengagement.

Pour le Cluster 0 (élèves performants)

- Proposer des projets d'enrichissement académique et un tutorat par les pairs (parrainage du Cluster I).



- Encourager la candidature à des filières ou dispositifs d'excellence sélectifs.

6. Question 4 – Système automatisé de suggestion d'orientation

Le proviseur s'interroge sur la possibilité d'utiliser un modèle d'apprentissage automatique pour suggérer une orientation scolaire (Scientifique ou Littéraire) à partir des seules mesures disponibles avant la délibération du conseil de classe (heures d'étude, assiduité, note de devoirs).

6.1 Comparaison des modèles prédictifs

Nous comparons quatre algorithmes classiques de classification, entraînés sur 80 % des données (200 élèves) et évalués sur les 20 % restants (50 élèves) :

Modèle	Exactitude	Score F1
Forêt Aléatoire (Random Forest)	0,92	0,92
Arbre de décision (Decision Tree)	0,90	0,90
K plus proches voisins (KNN)	0,90	0,90
Régression Logistique	0,90	0,90

La Forêt Aléatoire obtient les meilleures performances sur le jeu de test, avec une exactitude et un score F1 de 0,92, légèrement au-dessus des trois autres modèles qui obtiennent tous 0,90. Elle est donc retenue comme modèle de suggestion automatique. En tant que méthode d'ensemble agrégeant de nombreux arbres de décision, elle offre en outre une bonne robustesse au bruit présent dans les données comportementales.

6.2 Analyse détaillée du modèle retenu

La matrice de confusion sur les 50 élèves du Jeu de test (25 de filière Littéraire, 25 de filière Scientifique) est la suivante :

	Prédit Littéraire	Prédit Scientifique
Réel Littéraire	23 (Vrais Négatifs)	2 (Faux Positifs)
Réel Scientifique	2 (Faux Négatifs)	23 (Vrais Positifs)



Figure 5 – Matrice de confusion du modèle de Forêt Aléatoire sur le Jeu de test ($n = 50$).

- Filière Littéraire : précision et rappel de 0,92 (23 bonnes classifications sur 25 élèves réellement Littéraires).

- **Filière Scientifique : précision et rappel de 0,92 (23 bonnes classifications sur 25 élèves réellement Scientifiques).**

Les erreurs sont parfaitement symétriques (2 faux positifs, 2 faux négatifs), ce qui indique que le modèle ne favorise structurellement aucune des deux filières : il ne pousse pas artificiellement davantage d'élèves vers la filière Scientifique ou vers la filière Littéraire.

6.3 Évaluation des risques pédagogiques

- **Faux positifs (2 cas) :** élèves orientés par erreur vers la filière Scientifique alors qu'ils auraient dû être orientés en Littéraire. Ils risquent de se retrouver en difficulté face aux exigences des matières scientifiques de terminale.
- **Faux négatifs (2 cas) :** élèves orientés par erreur en Littéraire alors qu'ils présentaient un profil plutôt Scientifique. Ce type d'erreur peut freiner des vocations scientifiques légitimes en limitant les ambitions académiques de l'élève.

6.4 Limites éthiques et techniques de l'automatisation

- **Biais quantitatif :** le modèle n'analyse que l'effort mesurable (heures, présence, notes de devoirs). Il ignore le projet d'avenir de l'élève, ses préférences personnelles, ses passions et sa motivation propre.
- **Rigidité algorithmique :** le modèle fige des corrélations observées sur une cohorte donnée ; si le niveau général, le programme ou les modalités d'examen évoluent, ses prédictions deviennent obsolètes et doivent être réentraînées.
- **Recommandation :** avec une exactitude de 0,92, le système peut être utilisé comme outil d'aide à la décision pour présélectionner les dossiers évidents, mais ne doit jamais remplacer la délibération humaine du conseil de classe – en particulier pour les élèves dont la probabilité prédite est proche de 50 %, qui doivent systématiquement faire l'objet d'un examen individuel **approfondi**.

7. Conclusion

Ce travail pratique a permis de mettre en évidence l'apport de l'analyse de données pour la gestion pédagogique d'un établissement d'enseignement secondaire. L'analyse statistique univariée a permis de caractériser un niveau global satisfaisant et homogène (moyenne 69,1/100, médiane 69/100), sans décrochage massif ni performance hors norme, tout en identifiant l'élève le plus fragile comme point d'attention individuel.

L'analyse de régression multiple a quantifié l'impact de chaque comportement sur la réussite, prouvant que les heures de travail personnel, l'assiduité et la régularité des devoirs expliquent à elles seules 82,5 % de la variance de la note finale, tout en soulignant les limites de toute anticipation au-delà de cette marge d'incertitude.

Le partitionnement par K-Means a structuré la cohorte en deux profils équilibrés et pédagogiquement actionnables (élèves performants / élèves à accompagner), permettant d'orienter des politiques de soutien différenciées.

Enfin, la comparaison de quatre modèles supervisés a permis de concevoir un système prédictif d'orientation performant (Forêt Aléatoire, exactitude et FI de 0,92), tout en démontrant, chiffres à l'appui, qu'un tel système ne peut être qu'un outil d'aide à la décision : il doit rester subordonné au jugement humain du conseil de classe, notamment pour les cas d'indécision.